UNIVERSIDAD TECNOLÓGICA NACIONAL

Diplomatura en Ciencia de Datos y Análisis Avanzado

Trabajo práctico integrador

Grupo 4:

- Arbe Florencia
- González Hernán
- Ratti Marcelo
- Sciacca Marianela
- Sólimo Aldana

30 de marzo de 2026
Buenos Aires, Argentina

Contenido

Resumen ejecutivo.....3
Definición del problema y caso de negocio.....3
Relevamiento de Fuentes de Datos utilizado.....4
Análisis y resultados.....5
1. Análisis exploratorio de los datos:.....5
2. Feature engineering, modelado y validación:.....6
Estrategia 1: modelado sobre transacciones individuales.....6
Estrategia 2: feature engineering basado en comportamiento del usuario.....7
Conclusiones y Recomendaciones.....10
Impacto en el Negocio.....11
Código Python en Github:.....11
Anexo: Figuras suplementarias.....12

Resumen ejecutivo

La expansión de las billeteras virtuales ha intensificado la exposición al fraude digital. Los mecanismos tradicionales basados en reglas resultan insuficientes frente a patrones complejos y cambiantes, lo que afecta la capacidad de detección oportuna y eficiente.

El presente trabajo propone el desarrollo de un modelo de aprendizaje automático orientado a la detección automática de transacciones potencialmente fraudulentas antes de su aprobación definitiva. Está orientado hacia un público interno que está conformado por los equipos de riesgo, prevención de fraude y analítica, quienes podrán aplicar el modelo generado en los procesos de autorización y revisión manual.

En cuanto a los resultados, todos los modelos evaluados mostraron un desempeño limitado en la detección de fraude, con una tasa elevada de falsos positivos. La mejor combinación de capacidad de detección de fraude y aceptación de transacciones legítimas la mostró el Árbol de Decisión sin utilizar variables creadas que reflejaran el comportamiento de los usuarios. Los resultados sugieren que las variables disponibles no permiten capturar patrones relevantes, lo que restringe el poder predictivo de los modelos.

Definición del problema y caso de negocio

El aumento de los pagos digitales incrementa la exposición a transacciones fraudulentas, generando pérdidas económicas, mayores costos operativos por revisiones manuales, riesgo reputacional y complicaciones para usuarios legítimos debido a falsos positivos. Los enfoques basados en reglas estáticas no capturan patrones complejos relacionados con comportamiento del usuario, contexto de dispositivo y características transaccionales, lo que limita la capacidad de detección temprana y prevención en tiempo real.

El objetivo del presente trabajo es generar un modelo que permita detectar posibles transacciones fraudulentas realizadas en una plataforma de pago virtual para evitar que los consumos impacten de manera automática.

Como objetivos medibles claves para la detección de fraude se seleccionó:

● Tasa de Contracargos: Mide las cantidad de transacciones disputadas respecto del total. Si supera el 1% se suele alertar a las redes de tarjetas.

● Tasa de Falsos Positivos: Mide las transacciones legítimas rechazadas erróneamente por el sistema de seguridad.

● Tasa de Pérdida por Fraude: Porcentaje de ingresos perdidos por transacciones fraudulentas aprobadas.

● Tasa de Aprobación/Rechazo: Proporción de transacciones autorizadas vs. bloqueadas.

El proceso de detección de fraude comienza con la captura de los datos de la transacción, los cuales son pre procesados y utilizados por un modelo de machine learning para generar un score de riesgo. En función de este valor, un motor de decisiones permite aprobar automáticamente las operaciones de bajo riesgo o derivar las de mayor riesgo a

revisión manual. Finalmente, los resultados obtenidos son retroalimentados al sistema, permitiendo mejorar continuamente el desempeño del modelo (Figura 1).

Como valor del modelo es importante remarcar que bloquear automáticamente transacciones de alto riesgo en tiempo real, permite evitar la revisión manual, reducir pérdidas económicas y mejorar la experiencia del usuario legítimo al bloquear menos.

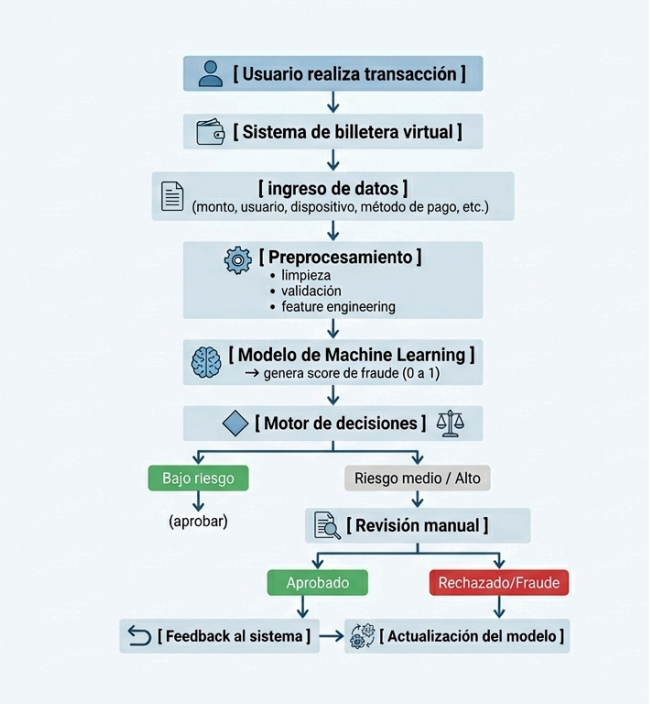

Figura 1. Proceso integral de detección de fraude dentro de una billetera virtual

Relevamiento de Fuentes de Datos utilizado

Se utilizó el "*Fraud Detection Dataset*" obtenido en la plataforma Kaggle (www.kaggle.com/datasets/ranjitmandal/fraud-detection-dataset-csv).

Este dataset contiene registro de 51.000 transacciones. Con las variables detalladas en la Tabla 1.

Variable	**Descripción**
User_ID	ID del usuario que realizó la transacción
Transaction_Amount	Monto de la transacción
Transaction_Type	Tipo de transacción
Time_of_Transaction	Hora de la transacción
Device_Used	Dispositivo utilizado
Location	Ubicación (ciudades en Estados Unidos)
Previous_Fraudulent_Transactions	Existencia de transacciones fraudulentas previas
Account_Age	Antigüedad de la cuenta

Number_of_Transactions_Last_24H	Cantidad de transacciones en las últimas 24 horas
Payment_Method	Método de pago
Fraudulent	Fraudulenta (Si/No)

Tabla 1. Descripción de las variables presentes en el dataset *Fraud Detection*

Análisis y resultados

1. Análisis exploratorio de los datos:

En el análisis exploratorio de los datos se determinó la frecuencia relativa de los datos clasificados como fraudulentos (0.05) y las transacciones no fraudulentas (0.95) lo que evidencia un claro desbalance en el set de datos utilizados.

Una vez identificado este desbalance, se evaluaron las distribuciones de ambas condiciones para las variables numéricas (monto de la transacción, hora de la transacción, cantidad de transacciones fraudulentas previas, antigüedad de la cuenta, cantidad de transacciones en las últimas 24 horas) observándose gran similitud en el comportamiento de los datos (Figura S1). En los gráficos de caja se puede ver que casi no se separan las transacciones fraudulentas de las no fraudulentas, siendo su mediana y media similares en ambas condiciones (Figura S2). Es importante destacar que la única variable que mostró datos atípicos fue la variable monto de la transacción independientemente de si la transacción fue fraudulenta o no. Como se mencionó en la pre-entrega de este trabajo se decidió no eliminar dichos valores, ya que representan transacciones de monto elevado que podrían estar asociadas a un mayor riesgo y, por lo tanto, resultar relevantes para la detección de fraude. Además, la amplia dispersión observada en esta variable sugiere que el comportamiento de las transacciones podría no ser homogéneo a lo largo de distintos rangos de monto (Figura S1). Sin embargo, evaluando específicamente el porcentaje de fraude de acuerdo al monto de transacción separado en cuartiles, se observó que el mismo mantiene la misma proporción lo que no permite mostrar una capacidad discriminatoria para la detección del fraude de acuerdo al monto (Figura S3).

A continuación, se evaluó el comportamiento de las variables categóricas al analizar las tablas de contingencia con frecuencias absolutas. Como se puede observar en la figura S4, las distintas categorías de las variables tipo de transacción, dispositivo utilizado, ubicación y método de pago presentan volúmenes de transacciones relativamente similares. Asimismo, la cantidad de transacciones fraudulentas dentro de cada categoría es comparable entre sí, donde la proporción de fraude se mantiene cercana al 5% para la mayoría de las categorías. Estos resultados sugieren que ninguna de las variables categóricas consideradas posee, de manera individual, una capacidad discriminatoria fuerte para identificar transacciones fraudulentas. En conjunto, tanto el análisis de variables numéricas como categóricas sugiere la ausencia de patrones claros que permitan diferenciar entre transacciones fraudulentas y no fraudulentas, ya que hasta el momento se ha identificado que ambos tipos de variables poseen un 5% aproximadamente de casos positivos.

Antes de continuar con el análisis haciendo la correlación de Spearman (tipo de correlación elegida debido a la posible ausencia de normalidad de acuerdo a la distribución de los datos) con el objetivo de detectar relaciones entre estas variables, se realizó un proceso de imputación, completando los valores faltantes en variables categóricas con la categoría “Unknown” y en variables numéricas con la mediana. Asimismo, se excluyeron las variables Transaction_ID y User_ID por no aportar

información relevante para este análisis exploratorio de datos. Como resultado en la figura S5, se observa que las variables en general presentan coeficientes cercanos a cero respecto a la variable objetivo (*Fraudulent*), indicando una débil relación. Asimismo, no se identifican correlaciones relevantes entre variables independientes que sugieran estructuras latentes claras. Este comportamiento evidencia una baja capacidad explicativa del conjunto de variables disponible, lo que podría limitar el desempeño de los modelos de clasificación en etapas posteriores.

Frente a la escasa capacidad discriminatoria de las variables numéricas y categóricas, una posible estrategia para predecir el fraude puede ser utilizar modelos agrupando los datos según el comportamiento de los usuarios, es decir, se puede entrenar un modelo con un agrupado previo para distinto tipo de transacciones con el objetivo de capturar patrones de fraude potencialmente diferentes en cada segmento.

2. Feature engineering, modelado y validación:

Debido a la calidad del *dataset* identificada en la sección de análisis exploratorio de los datos y con el objetivo de obtener un modelo que pueda predecir con precisión y confianza las transacciones fraudulentas, se decidió implementar diferentes estrategias incrementando la complejidad del análisis de los datos. Inicialmente, se evaluaron las transacciones como independientes, es decir, sin tener en cuenta la variable User_ID. Sin embargo, frente a los resultados obtenidos se decidió aplicar una segunda estrategia que intenta analizar el comportamiento de los usuarios asumiendo que las transacciones fraudulentas son las últimas en ser realizadas para ser comparadas con el comportamiento histórico del usuario en cuestión. Esta estrategia se basa en una hipótesis simplificada sobre el comportamiento del fraude, que puede no reflejar escenarios reales. La ausencia de información temporal completa limita la capacidad de modelar correctamente la secuencia de transacciones.

Para el modelado se separó al dataset en conjuntos de entrenamiento y validación, se aplicó escalado y se corrigió el desbalance utilizando SMOTE sobre el set de entrenamiento.

<u>Estrategia 1: modelado sobre transacciones individuales</u>

En una primera estrategia, se trabajó con el *dataset* procesado a nivel de transacción individual. Para ello, una vez finalizado el preprocesamiento (imputación de valores faltantes, codificación de variables categóricas mediante one-hot encoding y exclusión de identificadores sin valor predictivo como Transaction_ID y User_ID) se definieron los conjuntos de entrenamiento y testeo mediante una partición 70-30, con el objetivo de conservar en ambos subconjuntos la misma proporción de casos fraudulentos y no fraudulentos observada en el *dataset* original. Dado el desbalance existente entre clases, se incorporaron mecanismos de ponderación de clases en los modelos que lo permitían, buscando penalizar en mayor medida los errores sobre la clase minoritaria.

La selección de modelos se realizó con el objetivo de evaluar distintos tipos de relaciones potenciales entre las variables explicativas y la ocurrencia de fraude. En primer lugar, se utilizó regresión logística como base para analizar si había relaciones lineales entre las variables y el fraude. A continuación, se incorporaron modelos basados en similitud local (KNN) y modelos basados en reglas (árbol de decisión), con el fin de identificar posibles agrupamientos o reglas simples que permitieran discriminar entre clases. Posteriormente, se evaluaron modelos de ensamble como Random Forest y métodos de boosting (LightGBM y CatBoost, maneja mejor variables categóricas y se comporta mejor cuando hay ruido o la señal es débil), los cuales son capaces de capturar interacciones no lineales

y relaciones complejas entre variables. Estos modelos son utilizados para resolver problemas de clasificación en datos tabulares, por lo que su inclusión permite evaluar el máximo potencial predictivo del *dataset*. Finalmente, se incorporaron redes neuronales profundas (DNN) como alternativa para modelar patrones altamente no lineales y combinatorios cubriendo un amplio espectro de modelos para predecir el comportamiento de este *dataset.*

La validación se realizó sobre el conjunto de testeo, reportando métricas acordes al problema de fraude: ROC-AUC, PR-AUC, F1-score, accuracy, recall y precisión. La elección de estas métricas respondió a que, en contextos de clases desbalanceadas, la accuracy por sí sola puede resultar engañosa, mientras que recall, precision y PR-AUC permiten evaluar con mayor claridad la capacidad del modelo para detectar fraude sin generar una cantidad excesiva de falsos positivos.

Los resultados obtenidos mostraron desempeños muy limitados en prácticamente todos los modelos, con valores de ROC-AUC cercanos a 0.5 y PR-AUC apenas por encima de la prevalencia de la clase positiva (Tabla 2). Esto indica que, aun utilizando algoritmos lineales, de árboles, boosting y deep learning, la información contenida en las variables disponibles no resulta suficiente para discriminar adecuadamente entre transacciones fraudulentas y no fraudulentas. En otras palabras, el problema no pareció estar asociado al tipo de modelo utilizado, sino más bien a la baja señal predictiva presente en el dataset.

Estrategia 2: feature engineering basado en comportamiento del usuario

Dado que el dataset contiene 51.000 transacciones correspondientes a aproximadamente 4.000 usuarios únicos, en una segunda estrategia se decidió incorporar información relacionada con el comportamiento histórico de cada usuario. La motivación de este enfoque fue que, en problemas reales de fraude, muchas veces una transacción no resulta sospechosa por sus características aisladas, sino porque representa una desviación respecto del patrón habitual de uso del usuario. En este sentido, el fraude puede entenderse como una anomalía comportamental más que como una simple combinación estática de variables.

Se incorporaron nuevas variables con el objetivo de capturar patrones de comportamiento no evidentes en las variables originales. En particular, se definió una medida de intensidad de gasto (amount_per_txn_24h), que relaciona el monto con la actividad reciente del usuario, y una variable de frecuencia relativa (txns_per_day), que vincula las transacciones recientes con la antigüedad de la cuenta. Asimismo, se incluyó un indicador de historial de fraude (fraud_history_ratio) y una variable combinada de riesgo (risk_score) que integra monto, frecuencia y antigüedad. Finalmente, se agregó una variable binaria (amount_is_integer) para identificar montos redondos como posible patrón asociado a fraude.

Sumado a ello, se asumió que las transacciones fraudulentas se dieron posteriormente a las legítimas y que estas últimas son representativas del comportamiento usual de esos usuarios.Se generaron nuevas variables derivadas del comportamiento de cada usuario como el monto promedio por transacción, junto con su desvío y mediana, y se agregó al dataset la relación entre el gasto realizado y el monto promedio para cada usuario.

La lógica detrás de este feature engineering fue que ciertos cambios repentinos por ejemplo, una operación realizada desde un contexto distinto al habitual podrían estar asociados a una mayor probabilidad de fraude. Una vez construidas estas nuevas variables, se repitió el proceso de codificación, partición en entrenamiento y testeo, escalado cuando correspondía y entrenamiento de los mismos modelos utilizados en la estrategia anterior.

Sin embargo, los resultados no mostraron mejoras sustanciales respecto del enfoque basado en transacciones individuales. Aun incorporando variables de comportamiento por usuario, las métricas continuaron siendo bajas y cercanas al azar (Tabla 2). Esto sugiere que, al menos en este dataset, los cambios observables entre transacciones consecutivas no contienen suficiente información para identificar de manera robusta los casos fraudulentos. También es posible que la variable temporal disponible no represente adecuadamente un orden cronológico completo de las transacciones, lo que limita la calidad de las variables históricas construidas. Adicionalmente, ciertos cambios de comportamiento como utilizar diferentes dispositivos o ubicaciones pueden formar parte del uso normal de algunos usuarios, introduciendo ruido en lugar de señal.

Strategy	Model	ROC_AUC	PR_AUC	F1	Accuracy	Recall	Precision
Estrategia_1	Decision Tree	0.518861	0.052024	0.088448	0.765588	0.231076	0.054691
Estrategia_1	DNN	0.488011	0.047376	0.074842	0.798824	0.165339	0.048368
Estrategia_1	LogReg	0.511953	0.051107	0.069414	0.873824	0.095618	0.054484
Estrategia_1	KNN	0.502677	0.049625	0.057182	0.864216	0.083665	0.043433
Estrategia_1	Gradient Boosting	0.515900	0.051705	0.061934	0.878235	0.081673	0.049878
Estrategia_1	Random Forest	0.531586	0.058033	0.074369	0.931667	0.055777	0.111554
Estrategia_1	XGBoost	0.512003	0.050797	0.023529	0.926765	0.017928	0.034221
Estrategia_1	CatBoost	0.519043	0.051560	0.022039	0.930392	0.015936	0.035714
Estrategia_1	LightGBM	0.510493	0.050444	0.022654	0.940784	0.013944	0.060345
Estrategia_2	Decision Tree	0.503250	0.048491	0.081386	0.672451	0.294821	0.047209
Estrategia_2	DNN	0.564958	0.072177	0.088914	0.841275	0.157371	0.061961
Estrategia_2	KNN	0.514130	0.053004	0.085459	0.859412	0.133466	0.062852
Estrategia_2	LogReg	0.539621	0.056715	0.080292	0.876471	0.109562	0.063364
Estrategia_2	Gradient Boosting	0.529305	0.053190	0.064570	0.889216	0.077689	0.055241
Estrategia_2	Random Forest	0.574571	0.067990	0.063444	0.939216	0.041833	0.131250
Estrategia_2	XGBoost	0.569693	0.066976	0.052705	0.933039	0.037849	0.086758

Estrategia_2	LightGBM	0.575410	0.073119	0.046901	0.944216	0.027888	0.147368
Estrategia_2	CatBoost	0.567403	0.064626	0.037627	0.934804	0.025896	0.068783

Tabla 2. Performance de los modelos utilizando la estrategia 1 y 2.

Dentro de todos los modelos evaluados, el que mejor desempeño tuvo fue el Árbol de Decisión tanto para la Estrategia 1 como para la 2. Se intentó ajustar el umbral de decisión para ambos modelos, obteniéndose un threshold óptimo de 0,45 para la Estrategia 1 y 0,55 para la Estrategia 2 pero al evaluar las respectivas matrices de confusión, estos thresholds alteraban demasiado la tasa de falsos positivos, probablemente asociado al marcado desbalanceo entre transacciones fraudulentas y no fraudulentas por lo que se decidió seguir con el umbral estándar de 0,5.

Sin considerar las variables de comportamiento de usuario se reconoce al 23% de los casos de fraude en el dataset de prueba y este porcentaje sube a 29% considerando el comportamiento de los usuarios pero aumenta también la tasa de falsos positivos (Figura 2).

En la Figura 2 se pueden ver las variables con mayor contribución en cada modelo. Ambos coinciden en el uso de teléfono celular como un factor relevante.

Ninguno de los modelos tiene un poder predictivo fuerte pero, si se debe elegir uno, habría que comparar qué resulta más costoso para el negocio: la pérdida por transacciones fraudulentas no detectadas o la potencial pérdida de clientes por la mala experiencia del usuario al clasificar mal transacciones legítimas.

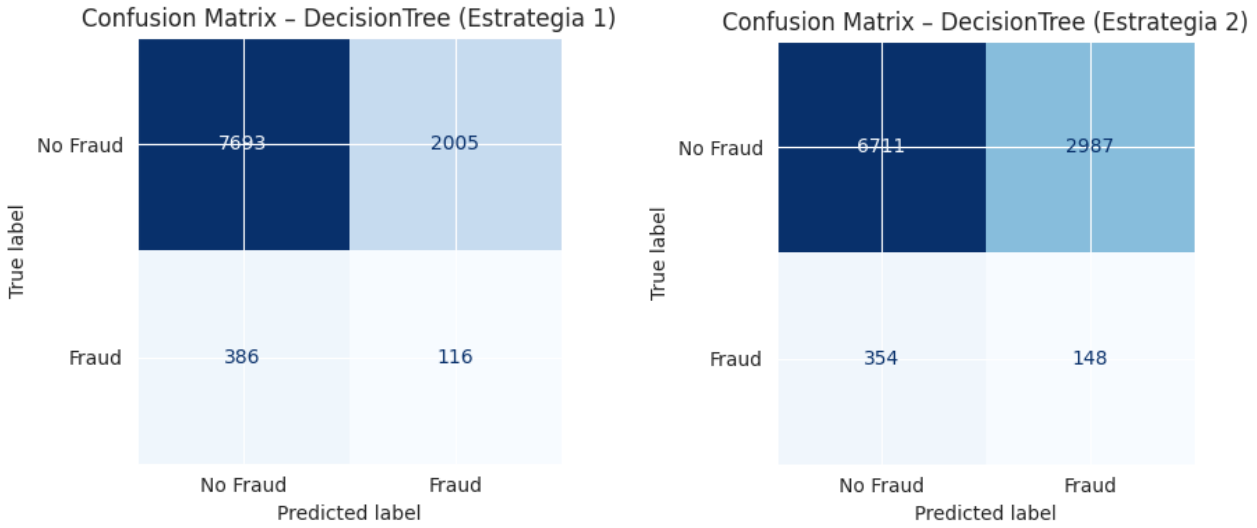

Figura 2. Matriz de confusión correspondiente al modelo Árbol de Decisión de la Estrategia 1 y 2.

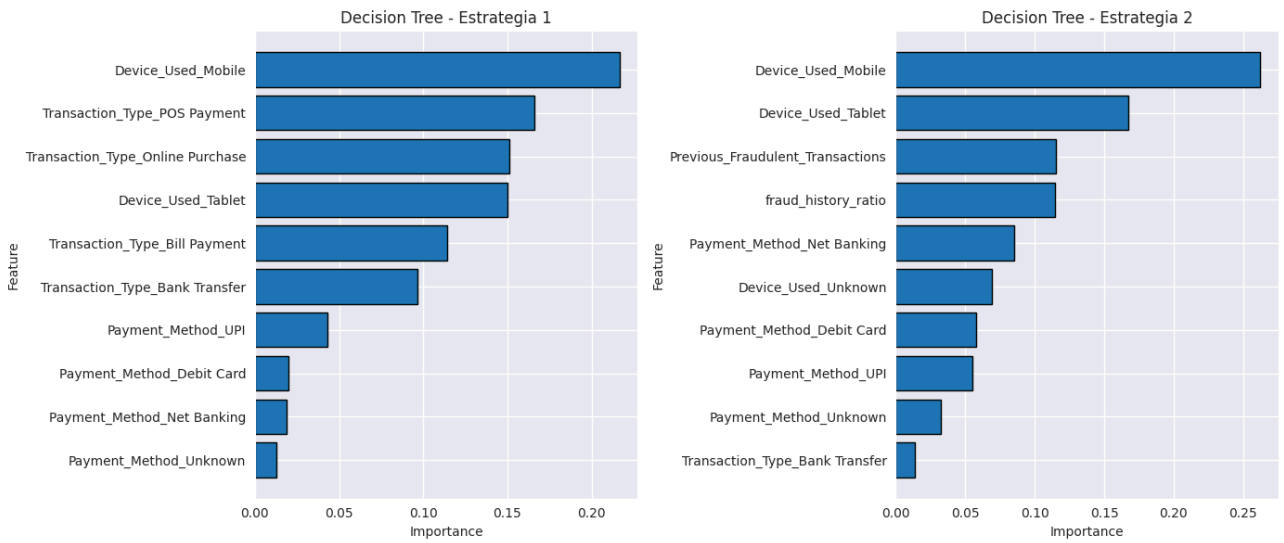

Figura 3. Variables con mayor contribución a la capacidad predictiva del modelo Árbol de Decisión de la Estrategia 1 y 2.

En la tabla 3 se muestran los KPI de negocio que podrían verse afectados por la implementación de los modelos. Con la Estrategia 1 la tasa de contracargos el ligeramente mayor pero también lo es la tasa de pérdida por fraude

La mayor tasa de rechazo de transacciones podría ser un problema para los usuarios legítimos y si se observa el monto perdido por fraude, la diferencia no es tanta como para justificar el 10% extra de rechazo de transacciones. La potencial pérdida de clientes sería un riesgo mayor por lo que se elige como mejor modelo, con sus limitaciones, el Árbol de Decisión sin considerar las variables de comportamiento de los usuarios.

Estrategia	Tasa de contracargos	Tasa de falsos positivos	Tasa de falsos negativos	Tasa de aprobación	Tasa de rechazo	Monto perdido por fraude
1	3.78%	20.67%	76.89%	79.21%	20.79%	1026032.04
2	3.47%	30.8%	70.52%	69.26%	30.74%	996608.15

Tabla 3. Key performance indicators y monto perdido por fraude de la estrategia 1 y 2.

Conclusiones y Recomendaciones

En conjunto, todas las estrategias permitieron concluir que el bajo desempeño no depende principalmente de los algoritmos utilizados, sino de las limitaciones del dataset. Por un lado, las variables originales mostraron escasa capacidad discriminatoria en el análisis exploratorio. Por el otro, incluso al incorporar variables derivadas del comportamiento del usuario, la performance se mantuvo cercana al azar y con una gran proporción de falsos positivos. Esto sugiere que el conjunto de datos no contiene patrones suficientemente marcados para explicar el fraude de manera confiable, al menos con las variables observadas.

En este sentido, una posible mejora del modelo requeriría la incorporación de variables que capturen con mayor profundidad el comportamiento del usuario y el contexto de las transacciones. En particular, resultaría relevante disponer de información temporal más detallada, métricas de comportamiento histórico (como montos y frecuencias habituales), datos de geolocalización y características más específicas del dispositivo. Asimismo, la inclusión de variables que reflejen relaciones entre entidades, como cuentas o dispositivos compartidos, podría aportar información clave para la detección de patrones de fraude más complejos. La integración de este tipo de datos permitiría enriquecer el dataset y potencialmente mejorar la capacidad predictiva del modelo.

Impacto en el Negocio

La aplicación de modelos de machine learning para la detección de fraude en billeteras virtuales permite reducir pérdidas económicas, optimizar costos operativos al disminuir la revisión manual y mejorar la experiencia del usuario al minimizar falsos positivos. Estos beneficios impactan directamente en la eficiencia, la conversión y la confianza en la plataforma.

No obstante, su implementación requiere inversión en datos, infraestructura y monitoreo continuo para adaptarse a cambios en los patrones de fraude. En este caso, el bajo desempeño de los modelos evidencia limitaciones en el dataset, ya que las variables disponibles no aportan suficiente capacidad discriminante para una detección efectiva.

A nivel operativo, el modelo podría integrarse en procesos de autorización en tiempo real, combinando decisiones automáticas con revisión manual en casos de mayor riesgo. Como próximos pasos, resulta clave enriquecer los datos con información de comportamiento, contexto temporal y relaciones entre entidades, junto con estrategias de actualización continua para mejorar su desempeño y escalabilidad.

Código Python en Github:

https://github.com/mf-arbe/TPintegrador_detecciondefraude

Anexo: Figuras suplementarias

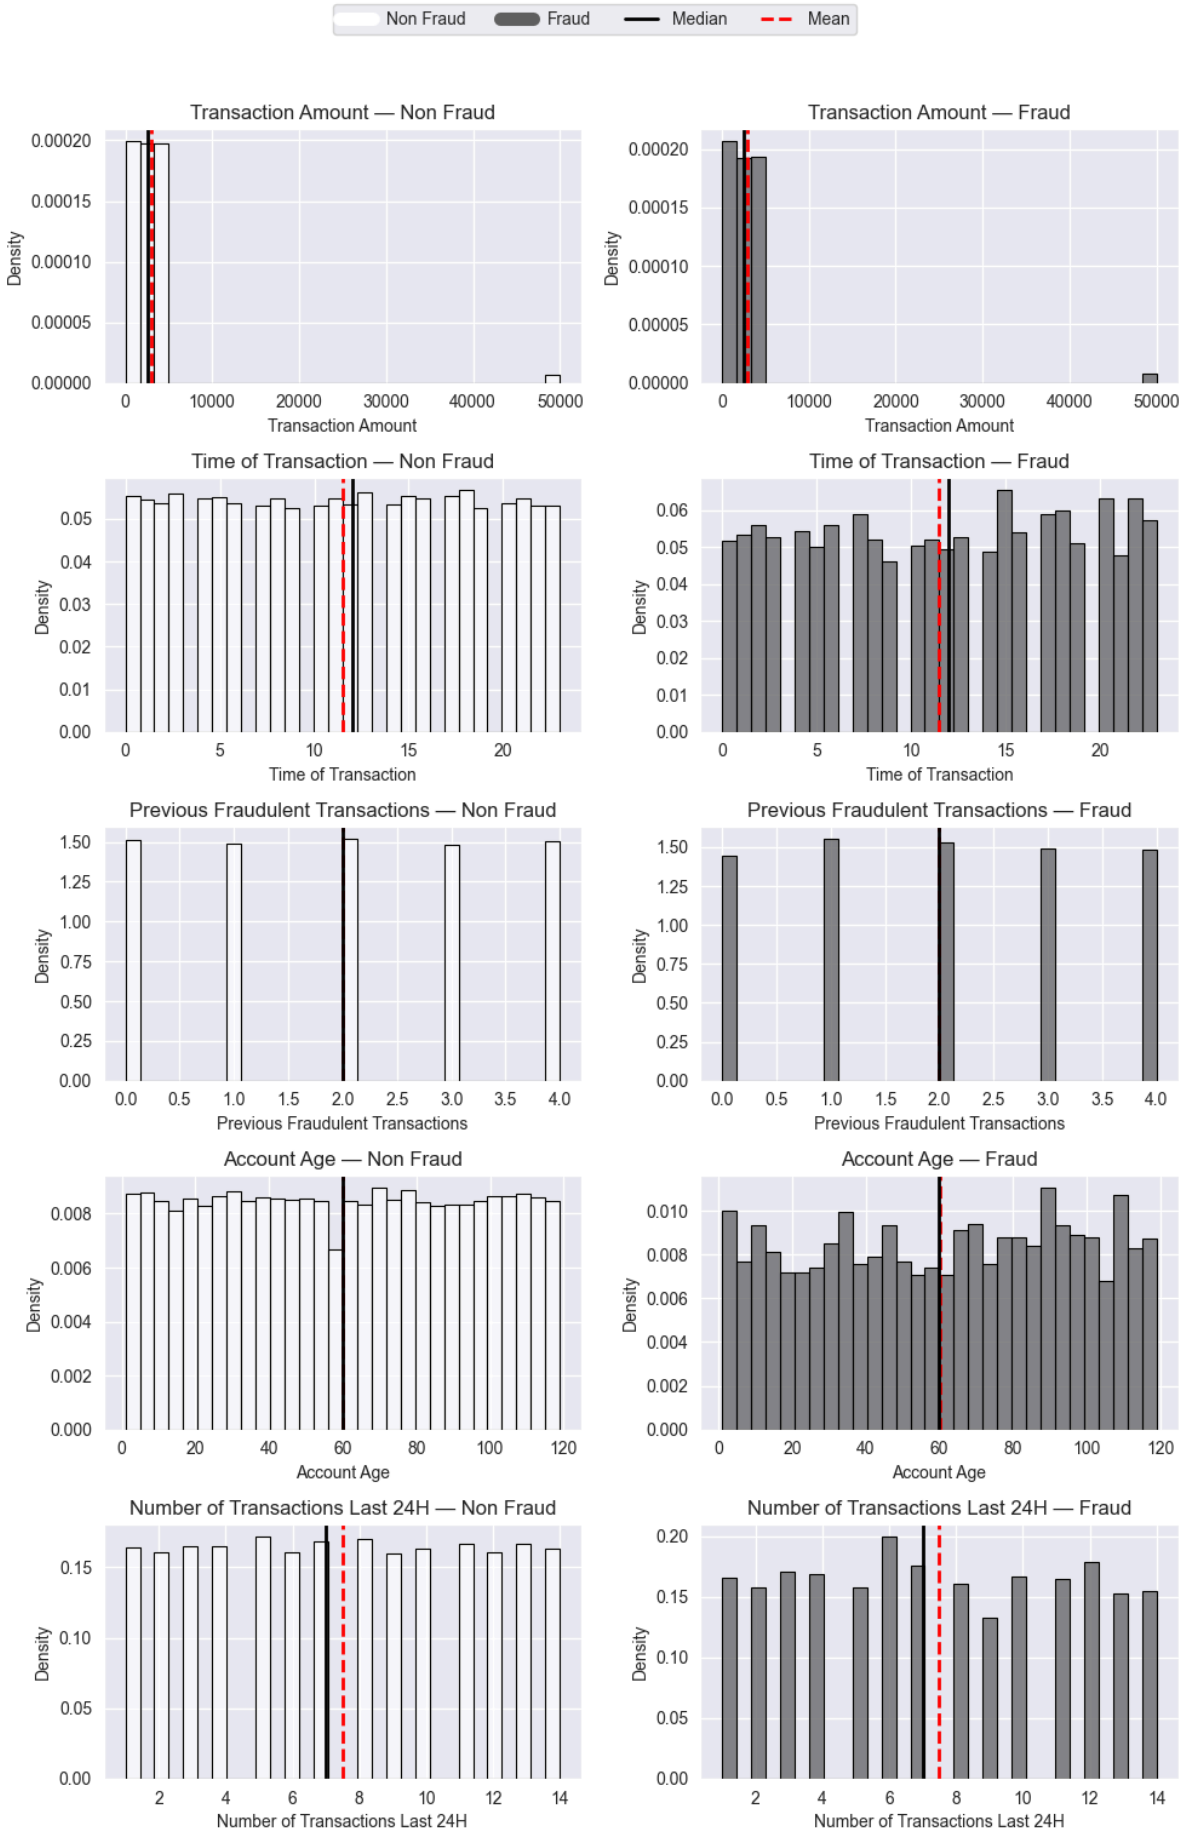

Figura S1: Distribución de las variables numéricas diferenciadas de acuerdo a si la transacción fue fraudulenta (gris oscuro) o no (gris claro).

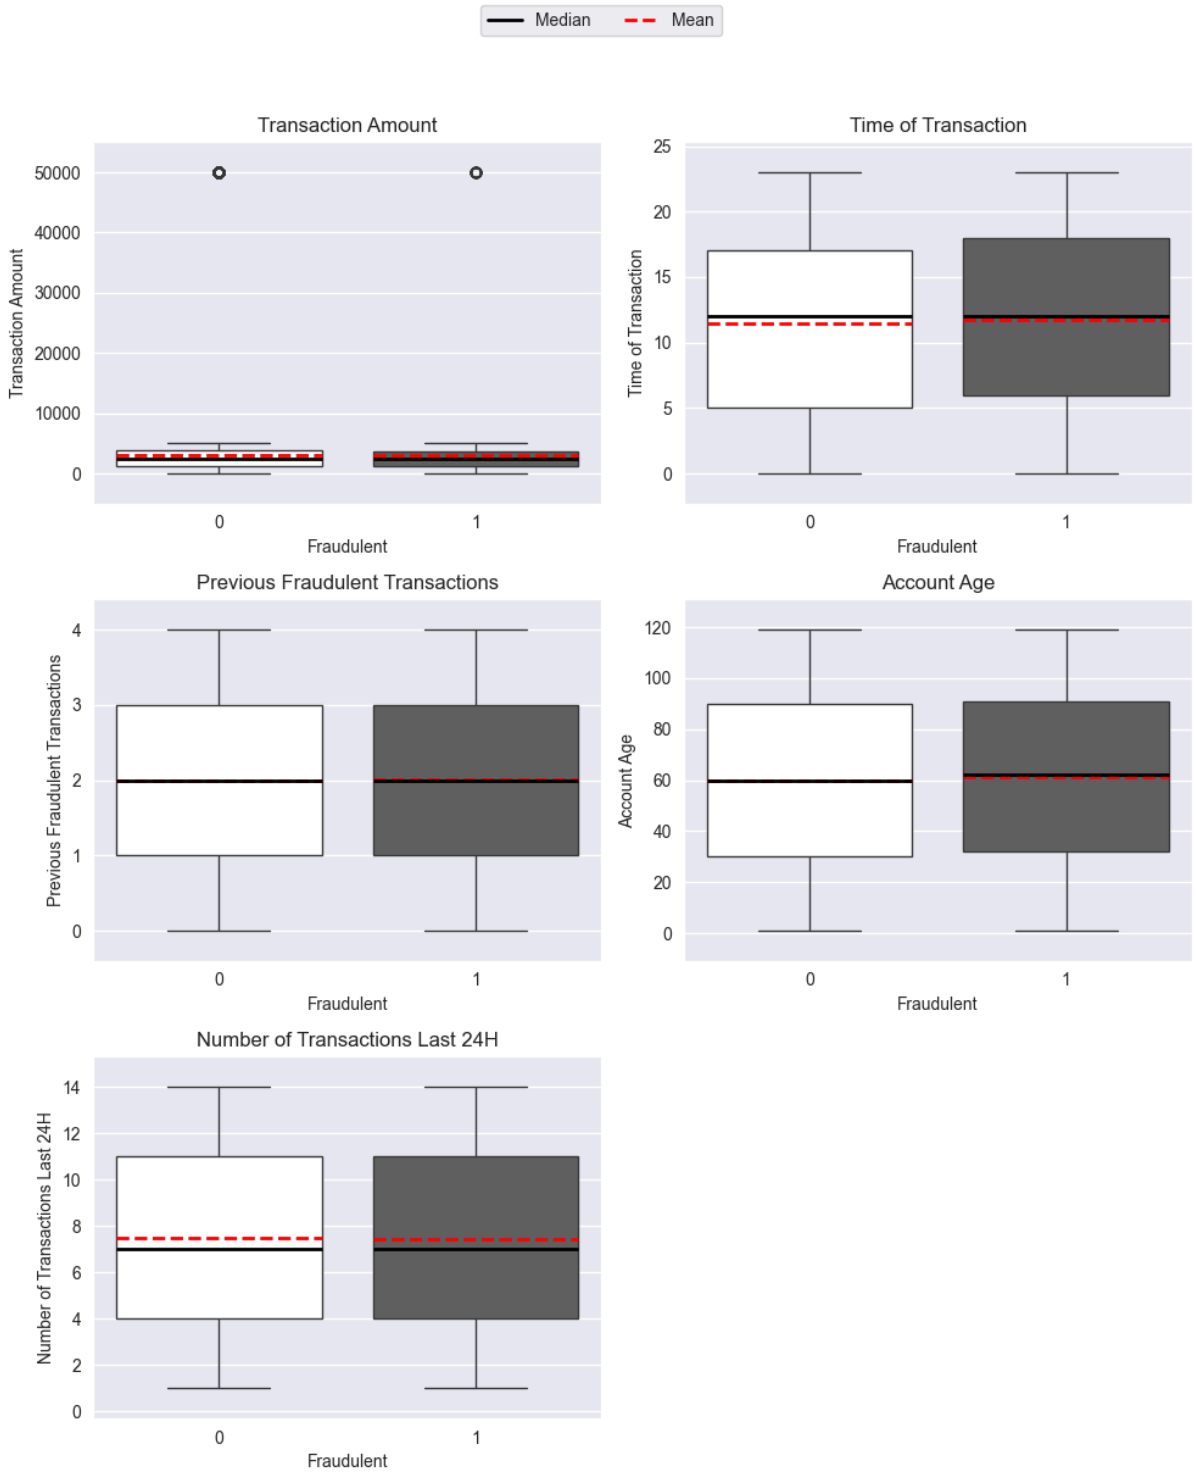

Figura S2: Boxplot de las variables numéricas diferenciadas de acuerdo a si la transacción fue fraudulenta (1: gris oscuro) o no (0: gris claro).

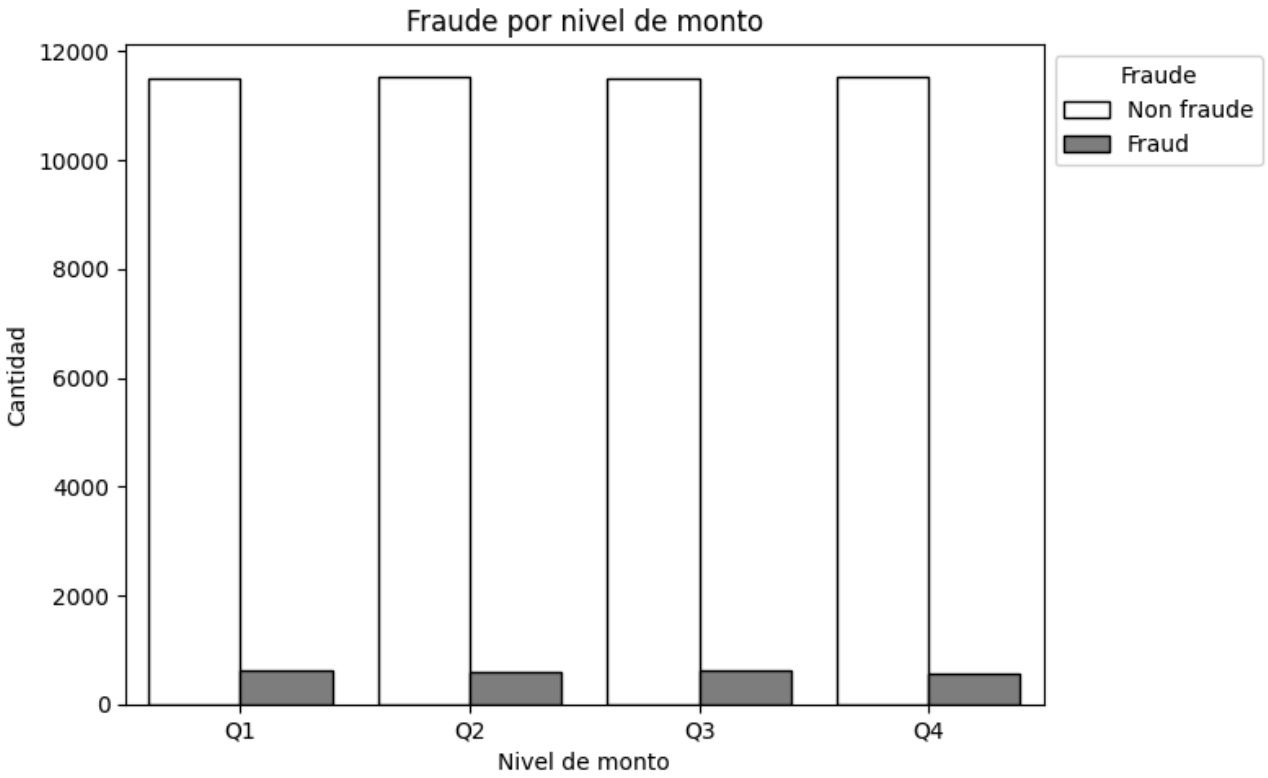

Figura S3: Proporción de fraude por nivel de monto. No se observan diferencias significativas entre los cuartiles de monto.

A.

Tipo de transacción	No fraudulento	Fraudulento
ATM Withdrawal	9691	473
Bank Transfer	9782	494
Bill Payment	9828	512
Online Purchase	9570	524
POS Payment	9619	507

B.

Dispositivo utilizado	No fraudulento	Fraudulento
Desktop	15047	748
Mobile	14808	806
Tablet	14859	729
Unknown Device	1455	75

C.

Ubicación	No fraudulento	Fraudulento
Boston	5839	310
Chicago	5737	334
Houston	5749	282
Los Angeles	5702	310
Miami	5693	298
New York	5820	290
San Francisco	5688	297
Seattle	5838	266

D.

Método de pago	No fraudulento	Fraudulento
Credit Card	11072	574
Debit Card	11230	572
Invalid Method	1457	73
Net Banking	11092	574
UPI	11275	612

Figura S4: Tablas de contingencias con frecuencias absolutas de las variables categóricas de acuerdo a si la transacción fue fraudulenta o no.

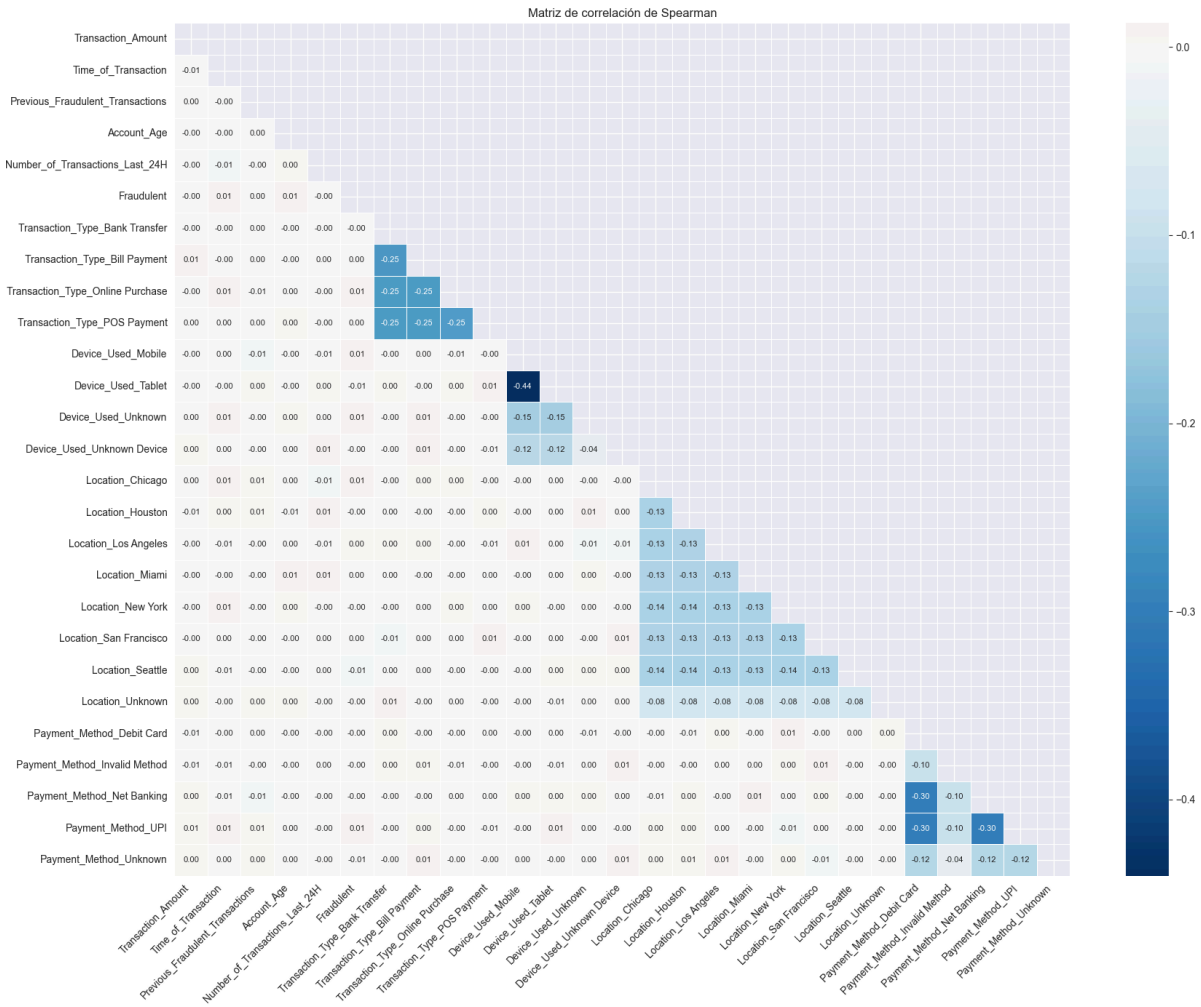

Figura S5: Matriz de correlación de Spearman entre las variables cuantitativas y categóricas luego del *one-hot encoding*.

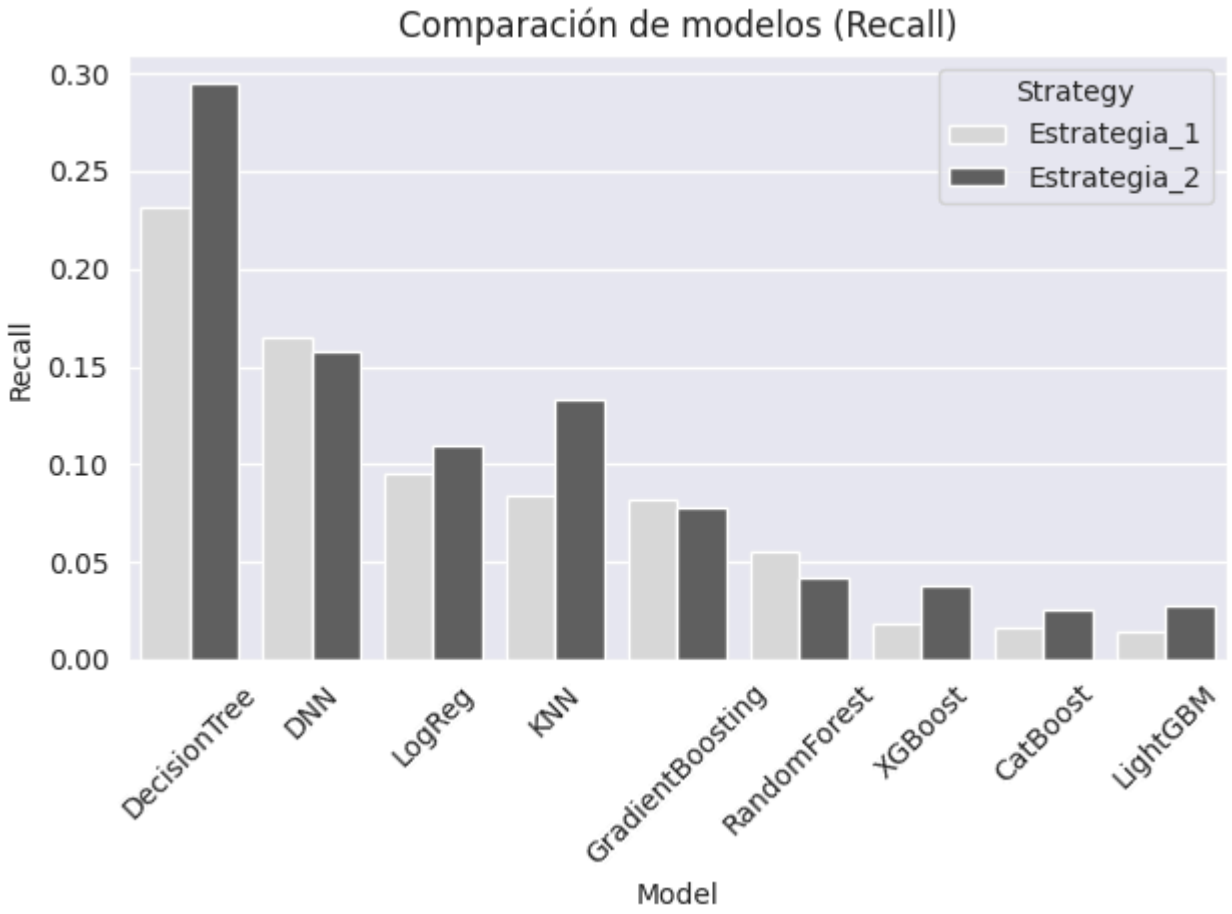

Figura S6: Comparación del recall entre modelos. Se observa un desempeño limitado en la detección de fraude, con valores bajos en la mayoría de los casos.

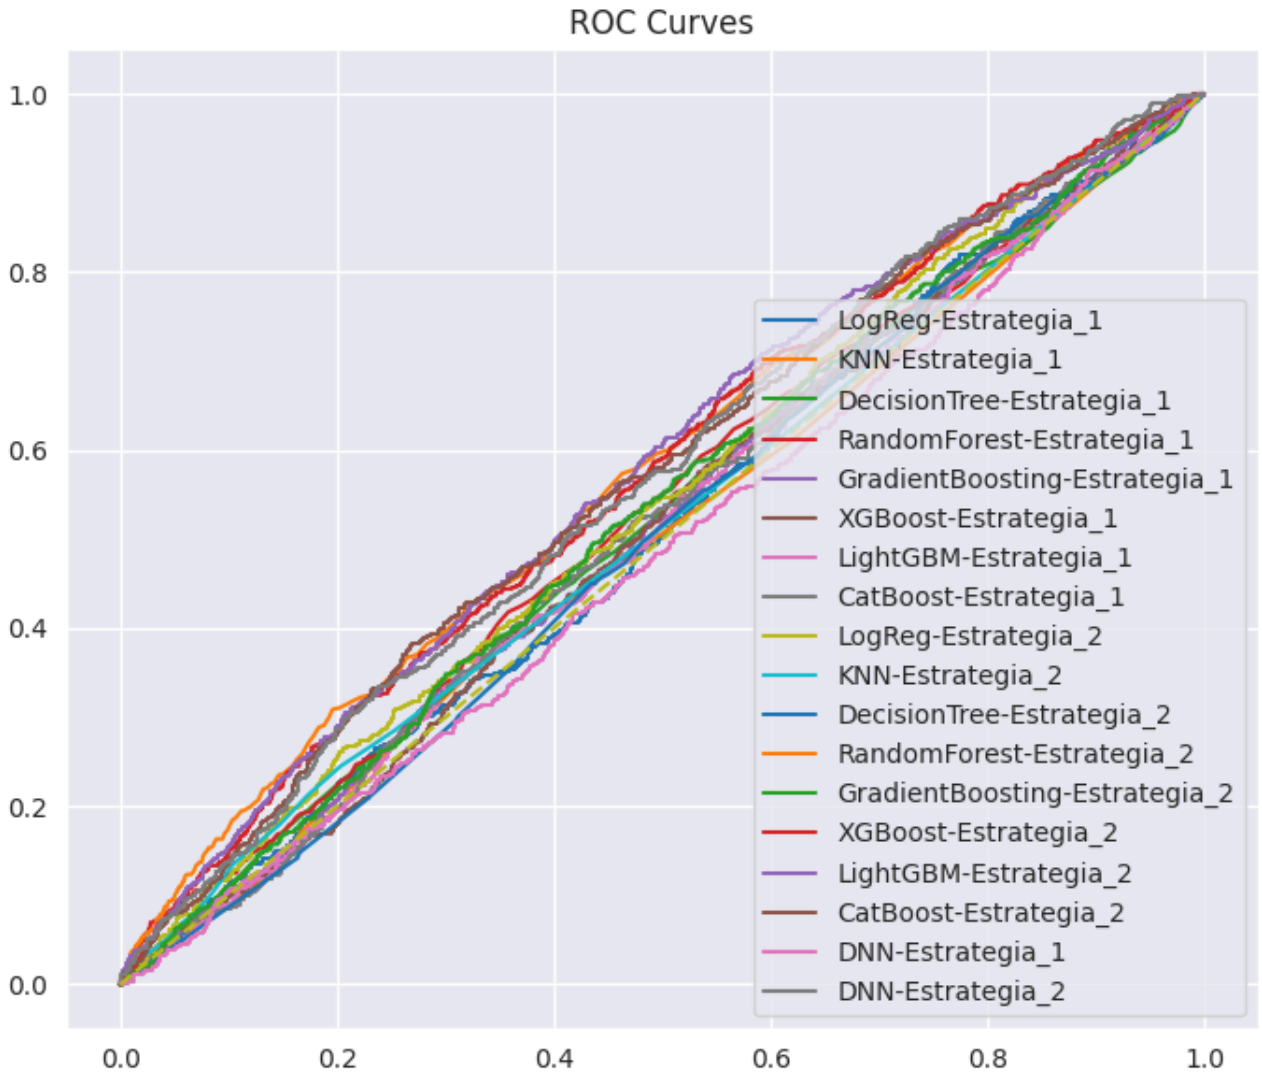

Figura S7: Curvas ROC de los modelos utilizados.